

Gold Dataset for the Evaluation of Bangla Stemmer

Tanim Ahmed, Sakhawat Hossain, Md. Shahidul Salim, Anika Anjum, K. M. Azharul Hasan

Department of Computer Science and Engineering

Khulna University of Engineering & Technology

Khulna, Bangladesh

ahmed1507113@stud.kuet.ac.bd, sakhawat3062@gmail.com, shahidulshakib034@gmail.com,

anikahermione@gmail.com, az@cse.kuet.ac.bd

Abstract—Stemming is a preprocessing task for Natural Language Processing(NLP) that involves normalizing inflected words representing the same concept of the original word. Steaming is a process of text normalization that transforms a slated word into its root form. It has a great impact in different applications in NLP and Natural Language Understanding. One of the biggest challenges in Bangla stemming is to collect the rules that are associated with Bangla word stemming and standard dataset for testing the accuracy. This paper presents a summery of rules associated with Bangla stemming and a gold standard dataset corpus which will helps to testify the stemming algorithm. We verify the rules and using our rules and corpus we tested with existing Bangla stemming algorithms and found that the proposed corpus makes a difference with existing techniques.

Index Terms—NLP, stemmer, lematizer, corpus, sentiment analysis, spell checker

I. INTRODUCTION

Stemming is a process by which a word is split into its stem and affix [1]. After the invention of stemmer, researchers are trying to increase the accuracy of the stemming algorithm. From the first to current different kinds of stemmer and the stemming process have been proposed. Stemmers are used for information retrieval and text mining. There are two kinds of stemming one is rule-based, another is corpus-based. Rule-based stemmer removes the suffix from the word and replaces this word with the null string. The corpus-based stemmers build a corpus with all possible combinations of the stemmed word. Every time it checks the word and replaces the word corresponding stemmer word. Corpus based is faster than the rule based stemmer and its accuracy rate is more than the rule-based. But they have a problem in corpus based. It must build a huge dataset for this and in this case memory complexity will be increased and it is a very tedious task to note all possible stemmed words. Moreover, if the corpus does not contain all forms of the standard word then the performance becomes poor. Therefore, a large number of languages support

rule-based stemmer. Because it is easy to build and needs lower memory complexity than the corpus-based. Popular stemmers are Porter Stemmer [2] [3], Lovins[4], Paice/Husk [5], Dawson [6] etc for English language. In Bangla several works have already been proposed [7] [8] [9]. A proper stemming process of any language increases the performance and reduces the dictionary size. For the performance evaluation process, we need a gold standard dataset. But there has been no effective recognized effort to develop a gold standard dataset. In this paper, we developed a rule-based corpus and using our corpus we evaluate the Bangla stemming algorithms. Our approach in this work is to develop a rule after analyzing the Bengali language. Bangla language uses affixed words more than the non-affixed words perhaps because the affixed words are informatively enriched than the non-affixed words [9][10]. Bangla infected words are in general verb (কিয়া বিভক্তি), noun (বিশেষ্য), number (বচন) etc. These rules are used to generate the corpus. These rules as well as the corpus are helpful to the improvement of the Bangla stemming algorithm. The corpus is open and can be found in [11]. The scheme can be applied to text mining for sentiment analysis [12], Parse design [13], Spam filter [14], and many others.

II. RELATED WORKS

A Rule-Based Bengali Stemmer is proposed in [15] that develops a rule-based stemming process that can extract stems from verb and noun without any database. Another rule-based stemmer for Bengali and Hindi is proposed in [16] where a faster and less error prone stemming method has been proposed for noun inflections only. They emphasize the classifiers and case markers and the title markers are dropped from the inflected word one by one. Then the plural suffixes and the derivational suffixes are dropped to reach the maximum length of the stem word. Another rules based stemmer was proposed where they used WordNet for detecting inflected words then apply rules for inflected word [17]. Their main problem was all the inflected words did not exist in wordNet. Corpus-based stemmers are proposed in [18][19]. [18] is based on

an unsupervised stemming algorithm that relies on the frequency of suffix appearing in a corpus of documents. A suffix is mentioned as a potential suffix if it exceeds a certain threshold value. The collection of words are then grouped by k equivalence classes. After that these equivalence classes are reformatted into several classes using a pre-defined threshold value and the final class is called potential class. The goal of [19] is to group words morphologically using their co-occurrence. The algorithm is developed using three main steps namely determination of words' pairs co-occurrence strength, re-calculation of strength using neighbors and finally based on the new strength group the words. [7] uses morphological stemming where simple suffix stripping is used for noun, adjective, and adverb and Minimum Edit Distance score is used to resolve the inflected words. [8] proposed the design scheme of a system of stemming Bengali words tagged with respective parts of speech dealing with orthographic syllables. A tagged token is sent to the stemming engine that produces a set of candidate stems with their assigned ranks and associated inflection dealt by an ortho syllable handler. The inflections of different POS are kept in different sets and the inflections found at a certain time are kept in a stack. GRAS [20] developed a language-independent stemming algorithm that constructs a set of classes where each class contains morphologically related words from a distinct set of words. The word from the corpus is partitioned into several groups such that each pair of words drawn from a group has the longest common prefix of length at least a given threshold value and the frequencies of suffix pairs are computed. A recursive rule-based stemmer is proposed in [21]. They iterate the same word in the system and check the longest substring and remove this suffix. This process recursively eliminates multiple suffixes from a single word and retrieve more relative root. [22] build a stemmer and use the stemmer to build a pos tagger. The proposed model was tested in the Bangla corpus. Another rule-based stemmer is discussed in [15]. The stemmer tries to find inflection in the word and try to get inflected from the word. They developed a stemmer that works stepwise to get proper stem words from the original. A N-gram based stemmer was proposed where di-grams is applied with some similarity measurement [23].

III. STEMMING METHODOLOGY

In Bangla, the major suffixes are involved with the verb (ক্রিয়া), number (বচন) which includes noun and pronoun. Therefore, if we can successfully determine these suffixes then we will be able to build an effective stemmer. the stemmer effectiveness depends upon these tasks. For building our stemmer dataset have analyzed Bangla Grammar from different sources. And we have listed the most common suffixes that are found in repetition. Based on these suffixes, we develop the corpus for stemmer. Example 1, 2 and 3 shows some important suffixes that

are connected with the verb, numbers and miscellaneous Bangla words respectively for natural Bangla text. In English, we can see the suffixes of verbs are related as follows.

Do->Doing

Walk->Walking

The root verbs are do and walk. In Bengali these are such that: কর->করতেছি

কর-> করব

হাঁটা->হাঁটতেছি

In the above example, the root verb (ক্রিয়ামূল) are কর,হাঁটা

In this paper we detect the suffixes using the rules and detect the root word.

Example 1: Some verb suffixes ((ক্রিয়া বিভক্তি)) for bangla text: েছ, িয়েছ, ায়, াছি, ায়েছি, াচ্ছে, াতিস, ালাম, ালেন, াইলে, াইবি, াবেন, াইতে, াতেন, াচ্ছ, াইলি, াতাম, াইবে, াইব, ালি, ালে, াউক, াবো, াইস, ায়ো, াবে, াইও, াইয়, াবি, াতে, াছে, াক, াও, াইয়েছিলাম, াইতেছিলেন, াইয়েছিলাম, াইতেছিঁস, াইতেছিঁস, াইয়েছিঁলেন, াইয়াছিঁলেন, াইতেছিঁলাম, াইয়াছিঁলে, াইতিছিঁলি, াইয়েছিঁলি, াইয়াছিঁলি, াইয়েছিঁলে, াছিঁলাম, াইতেছিঁলে, াছিঁলেন, াইয়েছিঁস, াইয়েছিঁলি, াছিঁলে, াইয়াছিঁস, াইতেছিঁন, াইয়াছিঁন, াছিঁলি, াছিঁস, াইয়াছিঁ, াচ্ছেন, াইতেছিঁ, াইয়েছিঁ, াইয়াছে, াইয়েছে, াইতেছে, াইতেছে, াইতেন, াইলেন, াইতাম, াইতিস, াইবেন, াইলাম, াইয়েছ, াইয়াছ, িয়েছেন, িয়েছ, িয়েছিঁস, িয়েছিঁ, াইলি, াছিঁলি, িতেছিঁল, িয়াছিঁলে, েছিঁলেন, েছিঁলে, িয়াছিঁলি, েছিঁলি, িতেছিঁল, ছিল, িয়াছিঁলেন, িয়াছিঁলি, েছিঁলি, িয়াছিঁলাম, িবে, িয়াছিঁ, াইল

Example 2: Some number (বচন(বিশেষ্য-সর্বনাম)) suffixes for bangla text: ব্দ, মন্ডলী, কুজ, পুজ, গুজ, ব্দ, সমুদয়, সন্মূহ, বর্গ, রাশি, আবলি, খানা, গুলি, রাজি, নিকর, খানি, নিচয়, গুলো, মালা, যুথ, সকল, বলি, দেয়, এরা, দিগ, পাল, দাম, কুল, টা, রা, সব, গণ, টি, ান

Example 3: Some miscellaneous ((বিবিধ)) suffixes for bangla text: তে, ঠল, ঠ, টাই, ইতেছি, নোর, টার, সছে, স, লের, রলে, য়ে, তেই, লেই, নে, ছিল, রিতে, ললে, খে, নীর, লের, নের, লায়, ঠে, লায়, ময়ে, জের, রের, য়ে

The methodology first takes input as a string which is a sentence or paragraph. We use a word tokenizer so that we can tokenize the sentence in words. We remove stop words from the sentence. Some Bangla stops word such as অবশ্য অনেক অনেকেই অন্তত অথবা অথচ are removed if exists. Then we calculate the number of words and ignore the null word. We use an iteration where we check they have any not stemmed word and if the word is bochon suffix (বচন(বিশেষ্য-সর্বনাম)), we stemmed the word and remove the inflection. Again we check bivokti ((ক্রিয়া বিভক্তি)) suffix, if we get any inflection we remove the inflection and get an inflected word. We have extra another suffix set that helps to remove exceptional sets of the inflected word. Then we get a paragraph or sentence without inflection.

IV. RULE BASED COPUS GENERATION

In Bengali, the most suffixes are involved with the verb (ক্রিয়া), number, the number includes noun, pronoun, and also there remain some other suffixes. So, if we can successfully determine these suffixes then we will be able to build an effective stemmer. All stemmer effectiveness depends upon these tasks. For building our stemmer we have analyzed Bangla Grammar from different sources. And we have listed the most common suffixes that are found in repetition. These rules are given below. And further, we have given a practical example of how these rules are connected with Bangla sentences.

In this section, we have represented a gold standard dataset to clearly understand how the above rules are valid with our stemmer. In the example, the common representation is: $A \rightarrow B; S$ where A represents the suffixes and B represents the replacement with those suffixes and S representation the example with the sentence. Example: A simple example shows how the stemming works:

Input: (সে কাজটি করে)

Output: (সে কাজ কর)

Since our rules are: (টি- $\rightarrow$ ϵ , $\rightarrow$ ϵ)

A. Corpus with Rules:

Some important rules of the corpus is shown as follows:

া $\rightarrow$ ϵ ; সবার জন্য নিরাপদ পানি সরবরাহ করা আমাদের কাজ।
ই $\rightarrow$ ϵ ; ঢাকাই জামদানি বুনে চাই।
জন $\rightarrow$ ϵ ; সে একজন লড়াকু সৈনিক।
য়ান $\rightarrow$ ϵ ; সে একজন তেজিয়ান কবি।
গুলো $\rightarrow$ ϵ ; তাঁর আঁকানো ছবিগুলো সুন্দর।
রা $\rightarrow$ ϵ ; চোরেরা ধরালো আশুন।
লু $\rightarrow$ ϵ ; সে ছিল দয়ালু।
ী $\rightarrow$ ϵ ; তার বাবা ধনী ছিল।
ছে $\rightarrow$ ϵ ; চেয়ারম্যানের বিরুদ্ধে জোরপূর্বক জমি লিখিয়ে নেয়ার অভিযোগ উঠেছে।
ীয় $\rightarrow$ ϵ ; সে তার দলীয় লোক।
ই $\rightarrow$ ϵ ; সময়ই টাকা।
ের $\rightarrow$ ϵ ; আমি হৃদয়ের কথা বলিতে ব্যাকুল।
িলে $\rightarrow$ ϵ ; পড়িলে পারিবে।
টির $\rightarrow$ ϵ ; ছেলেটির কণ্ঠ মেয়েলি।
লি $\rightarrow$ ϵ ; ছেলেটির কণ্ঠ মেয়েলি।
ে $\rightarrow$ ϵ ; চলতি মাস থেকেই দোকানে বসছে ভ্যাট মেশিন।
ছে $\rightarrow$ ϵ ; চলতি মাস থেকেই দোকানে বসছে ভ্যাট মেশিন।
টা $\rightarrow$ ϵ ; তার কাপড়টা ময়লাটে।
টে $\rightarrow$ ϵ ; তার কাপড়টা ময়লাটে।
র $\rightarrow$ ϵ ; পাতার লালচে রোগ একটি শারীরবৃত্তীয় সমস্যা।
চে $\rightarrow$ ϵ ; পাতার লালচে রোগ একটি শারীরবৃত্তীয় সমস্যা।
য় $\rightarrow$ ϵ ; পাতার লালচে রোগ একটি শারীরবৃত্তীয় সমস্যা।
োয়া $\rightarrow$ ϵ ; ঘরোয়া ক্রিকেট খেলাও একটি সমস্যা কিনা প্রশ্ন সাকিবের।
াও $\rightarrow$ ϵ ; ঘরোয়া ক্রিকেট খেলাও একটি সমস্যা কিনা প্রশ্ন সাকিবের।
ের $\rightarrow$ ϵ ; ঘরোয়া ক্রিকেট খেলাও একটি সমস্যা কিনা প্রশ্ন সাকিবের।
ো $\rightarrow$ ϵ ; পড়ো তোমার প্রভুর নামে।
ুয়া $\rightarrow$ ϵ ; তার পাছে উঠা দেখেই বুঝা যায় সে একজন গাছুয়া।
টি $\rightarrow$ ϵ ; টেস্ট খেলুড়ে ১২ টি দেশ।

ুড়ে $\rightarrow$ ϵ ; টেস্ট খেলুড়ে ১২ টি দেশ।
তা $\rightarrow$ ϵ ; দক্ষতা ছাড়া সততা শক্তিশীল।
হীন $\rightarrow$ ϵ ; দক্ষতা ছাড়া সততা শক্তিশীল।
স্থ $\rightarrow$ ϵ ; গৃহস্থ বাড়ি থেকে বিষধর সাপ উদ্ধার।
ধর $\rightarrow$ ϵ ; গৃহস্থ বাড়ি থেকে বিষধর সাপ উদ্ধার।
হর $\rightarrow$ ϵ ; রোগহর তিজতাকে গ্রহণ করাই তার বৃত্তি।
াকে $\rightarrow$ ϵ ; রোগহর তিজতাকে গ্রহণ করাই তার বৃত্তি।
সহ $\rightarrow$ ϵ ; নিহতের মাথায় আঘাতসহ শরীরে একাধিক ক্ষতচিহ্ন দেখা গেছে।
সই $\rightarrow$ ϵ ; টেকসই উন্নয়নে তিনি জোর দেন তিনটি বিষয়ে।
শালী $\rightarrow$ ϵ ; করিম খুব শক্তিশালী।
মান $\rightarrow$ ϵ ; রহিম খুব বুদ্ধিমান।
ময় $\rightarrow$ ϵ ; আল্লাহ করুণাময় ও দয়াময়।
মতী $\rightarrow$ ϵ ; মেয়েটি বুদ্ধিমতী।
ীভূত $\rightarrow$ ϵ ; আয়নিক যৌগ পানিতে দ্রবীভূত হয়।
গুলোতে $\rightarrow$ ϵ ; মাংস খাওয়া কমিয়ে দেওয়াতে জোর দেওয়া হচ্ছে কিন্তু মাংসভুক দেশগুলোতে এ অবস্থা কেমন?
বিহীন $\rightarrow$ ϵ ; বিয়ের পর সুনীর মাত্রাবিহীন জীবনে যতি পড়ল।
টির $\rightarrow$ ϵ ; ওষুধটির বহুবিধ উপকার সম্পর্কে তিনি আমাদের অবহিত করলেন।
লেন $\rightarrow$ ϵ ; ওষুধটির বহুবিধ উপকার সম্পর্কে তিনি আমাদের অবহিত করলেন।
বিদ $\rightarrow$ ϵ ; বেতারযন্ত্রবিদ এই পদে একজন নিয়োগ দেওয়া হবে।
বিং $\rightarrow$ ϵ ; আট বছর বিদেশে বাস করে তিনি দেশে ফিরে এসেছেন যন্ত্রবিৎরূপে।
বান $\rightarrow$ ϵ ; তার বাবা ছিল ধনবান।
বাজ $\rightarrow$ ϵ ; এবার যুদ্ধবাজ বোল্টনকে বরখাস্ত করলেন ট্রাম্প।
লেন $\rightarrow$ ϵ ; এবার যুদ্ধবাজ বোল্টনকে বরখাস্ত করলেন ট্রাম্প।
ধর $\rightarrow$ ϵ ; ইরান এখন পরমানু শক্তিধর।
বন্ত $\rightarrow$ ϵ ; তাকে দেখে প্রাণবন্ত মনে হয়েছিল।
বতী $\rightarrow$ ϵ ; কলাবতীকে বর্ষায় রূপবতী দেখায়।
প্রদ $\rightarrow$ ϵ ; কবরের প্রথম ধাপ ভীতপ্রদ।
ের $\rightarrow$ ϵ ; কবরের প্রথম ধাপ ভীতপ্রদ।
ো $\rightarrow$ ϵ ; এ বিচার তার মনপুত হলো না।
ালের $\rightarrow$ ϵ ; সেকালের নবাব একালের বংশধর।
ানের $\rightarrow$ ϵ ; পাকিস্তানের সঙ্গে কূটনৈতিক সম্পর্ক জোরদার হচ্ছে।
তর $\rightarrow$ ϵ ; দীর্ঘ থেকে দীর্ঘতর হচ্ছে অবরোধ।
তম $\rightarrow$ ϵ ; বিশ্বের দীর্ঘতম নদী নীলনদ।
ুন $\rightarrow$ ϵ ; আপনার দায়িত্ব ও কর্তব্য পালন করুন।
তব্য $\rightarrow$ ϵ ; আপনার দায়িত্ব ও কর্তব্য পালন করুন।
জ $\rightarrow$ ϵ ; সে ছিল ধর্মজ্ঞ।
জাদা $\rightarrow$ ϵ ; বিশ্বের নামজাদা অর্থনৈতিক ম্যাগাজিন জার্নাল।
জ $\rightarrow$ ϵ ; যে খনিজ ডেকে এনেছে ক্যান্সার।
চর $\rightarrow$ ϵ ; একসময় বাংলাদেশে প্রচুর জলচর পাখি দেখা যেত।
াগত $\rightarrow$ ϵ ; শনিবার দিবাগত রাতে পবিত্র শবে কদর।
খোর $\rightarrow$ ϵ ; সে একজন গাঁজাখোর।
ই $\rightarrow$ ϵ ; তার পরিবারে তার বাবাই একমাত্র কর্মক্ষম।
কার $\rightarrow$ ϵ ; আজকালকার ছেলেমেয়েরা অনেক মেধাবী।
কল্প $\rightarrow$ ϵ ; জল জীবনকল্প, তাতেই এখন মন্থর মৃত্যুর ছাড়াছল হাতছানি।
কর $\rightarrow$ ϵ ; চিনি কোকেইন থেকেও ক্ষতিকর ও নেশাকর।
ওয়ালা $\rightarrow$ ϵ ; করিম ছিল দুধওয়ালা, তার ভাই ছিল রুটিওয়ালা।
অলা $\rightarrow$ ϵ ; ফিরে এসেছে হাতলঅলা পলিবাগ।
ের $\rightarrow$ ϵ ; আমি হৃদয়ের কথা বলিতে ব্যাকুল।
িয়া $\rightarrow$ ϵ ; তাকে দেখিয়া সে চেয়ে থাকিল।
ে $\rightarrow$ ϵ ; সে কাজ করে।
া নো $\rightarrow$ ϵ ; গাড়ি ধোয়ানো কাজে কর্মচারী চাই।
ায় $\rightarrow$ ϵ ; আমি তাকে পেয়েছি নিসকিন অবস্থায়।

ছে → ε; সে ভাত খাচ্ছে।
 ি তেছে → ε; সে দেখিল দুইজন মানুষ আসিতেছে।
 ি ত → ε; দেখিত, কে সঠিক বলতে পারো। শিক্ষক তাকে বুদ্ধিমান বলত।
 ি ব → ε; কোনোদিন দেখিব না তারে আমি।
 ব → ε; তার কথা শুনব ও মানব।
 ো → ε; কাজটি শেষ করেই আসো তাহলে।
 ে ও → ε; জয় করেও ভয় তবুও কেন যায় না?
 ে ছেই → ε; তারা ব্যাট বলের অনুশীলন তো করেছেই, সেই সাথে ফিল্ডিংয়ের।
 ছিলাম → ε; আমি ক্রিকেট খেলছিলাম।
 ে ইছি → ε; আমি তো ঠিক করেইছি পরেরবার একটু বেশি ছুটি নিয়ে আসব।
 ে ওছি → ε; আর তা করার সর্বোচ্চ প্রচেষ্টা আমি করেওছি।
 ে ইছিলাম → ε; তোমাকে বলেইছিলাম তাকে খেপিও না।
 টি → ε; আমি কাজটি করি না।
 ে ওছি → ε; দোকানে নানা রকম ফুল দেখেওছি।
 কে → ε; নিজেকে প্রণয় করাই ভাল থাকার মন্ত্র।
 ে → ε; আমারও দেশের মাটির গন্ধে ভরে আছে মন।
 লে → ε; ভালো করে পড়লে ভাল ফল পাবে।
 বে → ε; সে কাজটি করবে।
 ত → ε; কেউ তার কথা শুনত না।
 উক → ε; ভাবুক ছেলেটি আসলে কে ছিলেন?
 এন → ε; পুরোটা না পড়ে কমেটস করএন না।
 লেন → ε; আইপিসি সিআরপিসিতে ফের বদলের কথা বললেন অমিত শাহ।
 বেন → ε; কি করবেন পড়াশোনা শেষে?
 উন → ε; কাজটি করুন দয়া করে।
 ছি → ε; আমি এখন বই পড়ছি।
 হিস → ε; কি করছিস? পড়াশোনা কর।
 ছ → ε; কি বলছ এসব?
 ছি → ε; তোমার কথা বুঝছি না।
 ছেন → ε; তিনি বই পড়ছেন।
 ছে → ε; সে খেলা করছে।
 ে ছি → ε; আমি কাজটি করেছি।
 ে হিস → ε; এ অঙ্কটি করেছিস?
 টিতে → ε; মামলাটিতে কি প্রমাণের কথা বলছে সুপ্রিম কোর্ট?
 ছেন → ε; ক্যাডার পছন্দে প্রথমেই ভুল করছেন না তো?
 লাম → ε; বললাম তো এখন যাও পরে এসো।
 লুম → ε; বললুম তো পারব না।
 লি → ε; কি করলি, আমার সব কাজ নষ্ট করে দিলি।
 লে → ε; কিভাবে করলে এটা?
 লেন → ε; কিভাবে করলেন এত কঠিন কাজ?
 ে ছে → ε; সে বলল, সে ভুল করেছে।
 ছিলাম → ε; কবিতা পড়ছিলাম, কিন্তু সে বিরক্ত করল।
 ছিলুম → ε; এতক্ষণ অন্ধ করছিলুম।
 ছিলি → ε; কি করছিলি? এত দেরি কেন?
 ে ছিলে → ε; বলেছিলে আসবে, কিন্তু আস নাই।
 ে ছিলেন → ε; তিনি কাজটি করেছিলেন।
 ে ছিল → ε; আমেরিকা মহাদেশে ইউরোপীয়রা উপনিবেশ স্থাপন করেছিল।
 ে ছিলাম → ε; মাহফুজ আর আমি এক সঙ্গে অভিনয় করেছিলাম।
 ে ছিলুম → ε; আমি কবিতা রচনা করেছিলুম।
 ে ছিলি → ε; তুই ভুল করেছিলি।
 ে ছিলে → ε; তোমরা তখন বলেছিলে আপনি যা বলেছেন তাই করাই ভাল।
 ে ছেন → ε; তোমরা তখন বলেছিলে আপনি যা বলেছেন তাই করাই ভাল।
 ে ছিলেন → ε; জবানবন্দিতে যা বলেছিলেন নুসরাত খুনের কারিগর সিরাজ।
 ে ছিল → ε; নমরুদ ষড়যন্ত্র করে নবীকে হত্যার উদ্দেশ্যে আঙনে নিক্ষেপ করেছিল।

াব → ε; আমি সেখানে যাব।
 ি স → ε; পড়াশোনা করিস না।
 বে → ε; সে যাবে আমার সাথে।
 বেন → ε; তিনি কাজটি করবেন বলে করেন নাই।
 েন → ε; তিনি কাজটি করবেন বলে করেন নাই।
 বে → ε; সে কাজটি করবে।
 তাম → ε; প্রতি শুক্রবার আমরা ফুটবল খেলতাম।
 তুম → ε; শিলাইদহে পদ্মাতীরে সাহিত্যচর্চা নিয়ে নিবুতে বাস করতুম।
 হিস → ε; কি দেখছিস আমিই সে ছেলে যে তাকে মেরেছিল।
 ে ছে → ε; সে জামিন পেয়েছে কিন্তু শর্ত হলো মিডিয়ায় কথা বলতে পারবে না।
 তেন → ε; তিনি আগে ফুটবল খেলতেন।
 ত → ε; দাদা বলত, পড়াশোনা করে যে, গাড়ি ষোড়া চড়ে সে।
 রা → ε; ছাত্ররা খেলা দেখতে গেছে।
 ে রা → ε; শিক্ষকেরা জ্ঞান দান করেন।
 রা → ε; পাখিরা আকাশে উড়ে দেখিয়া হিংসায় পিপীলিকারা বিধাতার কাছে পাখা চায়।
 ে রা → ε; কাকেরা এক বিরাট সভা করল।
 গুলো → ε; অতগুলো কুমড়া দিয়ে কি হবে?
 নি → ε; মেয়েটি স্কুলে যায়নি।
 যুথ → ε; হস্তিযুথ মাঠের ফসল নষ্ট করেছে।
 দের → ε; এটাই করিমদের বাড়ি।
 তে → ε; একটি দেশ, সে দেখতে যেমনই হোক না কেন।
 টা → ε; ন্যাকামিটা রাখ।
 গোটা → ε; গোটা দুই কমলালেবু আছে।
 খানা → ε; দুখানা কম্বল চেয়েছিলাম।
 টাক → ε; পোয়াটাক দুধ দাও।
 টুকু → ε; সবটুকু ওষুধই খেয়ে ফেলো।
 তা → ε; দশতা কাগজ দাও।
 পাটি → ε; আমার একপাটি জুতা ছিড়ে গেছে।
 গুলিন → ε; পটলগুলিন নষ্ট হয়ে গেছে।
 শীল → ε; পৃথিবী পরিবর্তনশীল।
 শীলতা → ε; তার পরিবর্তনশীলতা আমাকে মুগ্ধ করেছিল।
 টা → ε; লোকটা রাস্তার ধারে বসে আছে।
 টাই → ε; সেই লোকটাই কাজ করছিল।
 টাও → ε; তার সাথে কালো লোকটাও ছিল।
 টাকে → ε; লোকটাকে ডাক।
 টাকেই → ε; লম্বা লোকটাকেই এই কাজে দরকার।
 টাকেও → ε; খাটো লোকটাকেও লাগবে।
 টি → ε; বিশ্বের পনেরটি দূষিত শহরের মধ্যে বারোটাই ভারতে।
 টিও → ε; তৃতীয় দিনটিও নিজেদের করে নিল বাংলাদেশ।
 টিতে → ε; প্রতি একশটি মুরগিতে বিশটিতে রোগ রয়েছে।
 ে র → ε; ১৬ই ডিসেম্বর বাংলাদেশের বিজয় দিবস।
 টিতে → ε; এই দিনটিতে সরকারী ছুটি থাকে।
 টিতেই → ε; এই দিনটিতেই আমাদের পরিপূর্ণ বিজয় এসেছে।
 টিতেও → ε; ইদের দিনটিতেও গাজায় ইসরাইলের হামলা।
 টে → ε; চারটে বই, তিনটে লোক।
 টো → ε; বই দুটো পড়ে অনেক ভালো লেগেছিল।
 টুকু → ε; নিজের ভালটুকু দিয়ে কাজ করো।
 খানা → ε; বইখানা দাও।
 খানি → ε; তার মুখখানি দেখে তাকে বিষন্ন মনে হয়েছিল।
 খানেক → ε; বছরখানেক পার হয়ে গেল তার দেখা নেই।
 ই → ε; সময়ই টাকা।
 ে ইছেলেনে → ε; আপনি তো বলেইছিলেন, কুরআন তিলাওয়াত আপনার প্রিয়?
 ে ইছিলাম → ε; আমি ঠিক করেইছিলাম এখন যে রকম ছোটদের গল্প লেখা

Table I
COMPARISON WITH DIFFERENT STEMMING ALGORITHM WITH THE
CORPUS

Stemmer	S1	S2	S3
Right Stemmed	125	129	180
Wrong From Candidate Stemmed	57	24	63
Need to stem	126	155	65
Wrong Stemmed	114	142	153

হয় সেইরকম লিখব না।

গুলো → ϵ ; যন্ত্রপাতিগুলো পরিকার করে রাখ।

সমূহ → ϵ ; ইউনিয়নসমূহ ধানদিয়া, ইসলামকোট, খালিশালী, মাগুরা, তেতুলিয়া।

সমস্ত → ϵ ; আদিম জাতিদের পক্ষে খাদ্যসমস্ত সভ্যতর জাতিদের অপেক্ষা অধিকতর কঠোর ও দুর্লভ।

কুল → ϵ ; পক্ষীকুল তার ফসলে আক্রমণ করেছিল।

গণ → ϵ ; ছাত্রগণ তাদের দাবি অধ্যাপকের কাছে পেশ করলো।

জন → ϵ ; ভক্তজন ও মিডিয়া কিভাবে পাপাত্মকে মহাত্মায় পরিণত করে।

দল → ϵ ; সমাজের উন্নয়নে যুবকদল গুরুত্বপূর্ণ ভূমিকা রাখে।

দের → ϵ ; কুয়েটে ছেলেদের ফলাফল ভালো।

পাল → ϵ ; রাখাল গরুরপাল লয়ে যায় মাঠে।

বর্গ → ϵ ; মৃত্যুর সময় তার সন্তানবর্গ উপস্থিত ছিল।

বৃন্দ → ϵ ; বালকবৃন্দ উপস্থিত ছিল অনুষ্ঠানে।

বাহিনী → ϵ ; তৈমুরের সৈন্যবাহিনী ছিল সুসজ্জিত।

মহল → ϵ ; আমার বন্ধুমহল বরগুনায় শীতবস্ত্র বিতরণ করেছিল।

সংঘ → ϵ ; বালকসংঘ ভাল একটি অনুষ্ঠানের আয়োজন করেছিল।

শ্রেণী → ϵ ; শ্রমিকশ্রেণী হরতাল ডাকল।

মন্ডলী → ϵ ; প্রবাস থেকে যুক্ত আছেন দর্শকমন্ডলী ও প্রতিনিধিবৃন্দ।

সকল → ϵ ; ভাইসকল আপনারা শান্ত হোন।

সাধারণ → ϵ ; যাত্রীসাধারণ মালামাল সম্বন্ধে রাখুন।

াদি → ϵ ; পুস্তিকাদি ধুলাবালিতে পরিপূর্ণ।

ালি → ϵ ; নজরুলের গ্রন্থাবলি ভালো।

গাছা → ϵ ; লাঠীগাছা নিয়ে এসো।

গুচ্ছ → ϵ ; পত্রগুচ্ছ চিঠিপত্রের জবাব দানের অনুষ্ঠান।

জাল → ϵ ; তবুও কেন এ মায়াজাল আমাকে তাড়িয়ে বেড়ায়।

দাম → ϵ ; যে নদী হারায় স্রোত চলিতে না পারে সহস্র শৈবালদাম বাঁধে আসি তারে।

পুঞ্জ → ϵ ; মেঘপুঞ্জ মেরুর দিকে সরে যাচ্ছে ক্রমবর্ধমান তাপমাত্রার প্রভাবে।

মালা → ϵ ; মেঘমালা আকাশে উড়ে যায়।

রাজি → ϵ ; বৃক্ষরাজি নিধনে আমাদের অক্সিজেন ব্যবস্থা হুমকিতে।

রাশি → ϵ ; বর্ষাকালে যেদিকে চোখ যায় শুধুই জলরাশি।

ান → ϵ ; বাংলাদেশ থেকে আগত হাজী হেবান ১২৭১৫৭।

V. PERFORMANCE ANALYSIS

To evaluate the dataset, we develop a system Proposed Stemmer(S3)[11] and compared with some other Bangla stemmer namely Rafi Kamal Stemmer (S1)[24], Sazid Islam Stemmer(S2)[25]. The performance of the corpus and rules is shown in Table 1. The summary of the dataset is as follows:

- Total Sentence: 316
- Total Word Counts: 1086
- No of candidate word(that should be stemmed) : 308

The parameters that are used in Table 1 are described as follows. By candidate word we mean the inflected word

that should be stemmed.

- Right Stemmed: The words that are correctly stemmed from the dataset.
- Wrong From Candidate stemmed: Wrongly Stemmed from candidate words.
- Need to stem: Stem that should be stemmed but not stemmed using the rules.
- Wrong Stemmed: Total number of words that are stemmed both from candidate and non candidate.

VI. CONCLUSION

Finding stem words is often required for vast application by readers, researchers, spell checking, Information Extraction, web search engine, domain analysis. We developed a bangla corpus for possible Bangla slanted words. We found comparative results with corpus for Bangla words stemming. Based on our corpus, we found existing stemmers do not work well as our corpus has a variety of stem words. We believe the corpus can be helpful for many researchers for bangla language specially for text mining, emotion mining, parser design and many more. The corpus can also be applied to parallel stemmer design with a very small modification.

REFERENCES

- [1] Frakes, W.B., Baeza-Yates, R.: Information retrieval: data structures and algorithms. Prentice-Hall, Inc. (1992)
- [2] Porter, M.F.: An algorithm for suffix stripping. Program (2006)
- [3] Joshi, A., Thomas, N., Dabhade, M.: Modified porter stemming algorithm. International Journal of Computer Science and Information Technologies 7(1), 266–269 (2016)
- [4] Lovins, J.B.: Development of a stemming algorithm. Mech. Transl. Comput. Linguistics 11(1-2), 22–31 (1968)
- [5] Paice, C.D.: An evaluation method for stemming algorithms. In: SIGIR'94. pp. 42–50. Springer (1994)
- [6] Dawson, J.: Suffix removal and word conflation. ALLC bulletin 2(3), 33–46 (1974)
- [7] Das, A., Bandyopadhyay, S.: Morphological stemming cluster identification for bangla. Knowledge Sharing Event-1: Task 3 (2010)
- [8] Sarkar, S., Bandyopadhyay, S.: Design of a rule-based stemmer for natural language text in bengali. In: Proceedings of the IJCNLP-08 workshop on NLP for Less Privileged Languages (2008)
- [9] Shakib, M.S.S., Ahmed, T., Hasan, K.A.: Designing a bangla stemmer using rule based approach. In: 2019 International Conference on Bangla Speech and Language Processing (ICBSLP). pp. 1–4. IEEE (2019)
- [10] Dash, N.S.: A descriptive study of bengali words. Cambridge University Press (2015)
- [11] https://github.com/Tanim-Ahmed/performance_evaluation_dataset
- [12] Taher, S.A., Akhter, K.A., Hasan, K.A.: N-gram based sentiment mining for bangla text using support vector machine. In: 2018 International Conference on Bangla Speech and Language Processing (ICBSLP). pp. 1–5. IEEE (2018)
- [13] Hasan, K., Mondal, A., Saha, A., et al.: Recognizing bangla grammar using predictive parser. arXiv preprint arXiv:1201.2010 (2012)
- [14] Schneider, K.M.: A comparison of event models for naive bayes anti-spam e-mail filtering. In: 10th Conference of the European Chapter of the Association for Computational Linguistics (2003)

- [15] Mahmud, M.R., Afrin, M., Razzaque, M.A., Miller, E., Iwashige, J.: A rule based bengali stemmer. In: 2014 International Conference on Advances in Computing, Communications and Informatics (ICACCI). pp. 2750–2756. IEEE (2014)
- [16] Ganguly, D., Leveling, J., Jones, G.J.: Dcu@ fire-2012: rule-based stemmers for bengali and hindi (2012)
- [17] Das, S., Pandit, R., Naskar, S.K.: A rule based lightweight Bengali stemmer. In: Proceedings of the 17th International Conference on Natural Language Processing (ICON). pp. 400–408. NLP Association of India (NLPAI), Indian Institute of Technology Patna, Patna, India (Dec 2020), <https://aclanthology.org/2020.icon-main.55>
- [18] Paik, J.H., Parui, S.K.: A fast corpus-based stemmer. *ACM Transactions on Asian Language Information Processing (TALIP)* 10(2), 1–16 (2011)
- [19] Paik, J.H., Pal, D., Parui, S.K.: A novel corpus-based stemming algorithm using co-occurrence statistics. In: Proceedings of the 34th international ACM SIGIR conference on Research and development in Information Retrieval. pp. 863–872 (2011)
- [20] Paik, J.H., Mitra, M., Parui, S.K., Järvelin, K.: Gras: An effective and efficient stemming algorithm for information retrieval. *ACM Transactions on Information Systems (TOIS)* 29(4), 1–24 (2011)
- [21] Das, B., Paul, T.: Development of bengali language stemmer. A Project Report
- [22] Hoque, M.N., Seddiqui, M.H.: Bangla parts-of-speech tagging using bangla stemmer and rule based analyzer. In: 2015 18th International Conference on Computer and Information Technology (ICCIT). pp. 440–444. IEEE (2015)
- [23] Sadia, R., Rahman, M.A., Seddiqui, M.: N-gram statistical stemmer for bangla corpus (12 2019)
- [24] <https://github.com/rafi-kamal/Bangla-Stemmer>
- [25] <https://github.com/sazid1462/py-bangla-stemmer>